

Tarea 1

Sol Astengo

Ejercicio 7 - Modelo Exponencial-Gamma

Y_i = Tiempo de vida útil del componente electrónico i (en miles de horas)

$$Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Exp}(\lambda)$$

$$p(y_i|\lambda) = \lambda e^{-\lambda y_i}$$

$$y = (y_1, \dots, y_n)$$

Parte 1

Para demostrar que $\lambda \sim \text{Gamma}(a, b)$ es conjugada debemos observar si la distribución posterior pertenece a la misma familia de modelos que la previa, entonces debemos verificar que, al combinar el modelo para los datos con una distribución previa Gamma, la distribución posterior pertenece también a la familia Gamma.

Utilizando el dato de que las y_i son iid,

$$p(y|\lambda) = \prod_{i=1}^n \lambda e^{-\lambda y_i} = \lambda^n e^{-\lambda \sum_{i=1}^n y_i}$$

$$p(\lambda) \propto \lambda^{a-1} e^{-b\lambda}$$

Usando la Regla de Bayes: $p(\theta|y) = \frac{p(y|\theta)p(\theta)}{p(y)}$ $p(\theta|y) \propto (y|\theta)p(\theta)$

$$p(\lambda|y) \propto (y|\lambda)p(\lambda)$$

$$p(\lambda|y) \propto \lambda^n e^{-\lambda \sum_{i=1}^n y_i} \lambda^{a-1} e^{-b\lambda}$$

Agrupando las potencias de λ y los términos exponenciales, obtenemos:

$$p(\lambda|y) \propto \lambda^{(a-1+n)} e^{-\lambda(b+\sum_{i=1}^n y_i)}$$

$$\lambda|y \sim \text{Gamma}(a+n, b+\sum_{i=1}^n y_i)$$

De esta forma, la distribución posterior de λ pertenece a la misma familia de distribuciones que la previa, ya que ambas son distribuciones Gamma. Por lo tanto, la distribución Gamma es conjugada para el modelo Exponencial.

Parte 2

Para interpretar los parámetros a y b de la distribución previa tenemos que recordar que n es la cantidad de componentes observados y $\sum_{i=1}^n y_i$ es la suma de horas de vida útil de todos los componentes en conjunto. Tomando en cuenta que a y b son parámetros relacionados con “datos previos”, podemos interpretar a como la cantidad equivalente de componentes observados previamente y b como la suma equivalente de sus horas de vida útil.

Parte 3

Con los siguientes datos:

- $n = 10$
- $\sum_{i=1}^n y_i = 45$ (*miles de horas*)
- $\lambda \sim \text{Gamma}(2, 1)$, osea $a = 2$ y $b = 1$

Calcular la media posterior de λ y de $E(Y) = 1/\lambda$

Para la media posterior de λ debemos calcular $E(\lambda|y)$:

$$E(\lambda|y) = \frac{a+n}{b+\sum_{i=1}^n y_i} = \frac{2+10}{1+45} \approx 0.26$$

Para la media posterior de Y :

$$E(E(Y)) = E_{\lambda|y}(1/\lambda) = \int_0^\infty \left(\frac{1}{\lambda}\right) p(\lambda|y) d\lambda$$

Sabemos que con los datos dados $\lambda|y \sim \text{Gamma}(12, 46)$

Calculamos $\int_0^\infty \left(\frac{1}{\lambda}\right) p(\lambda|y) d\lambda$

```
integrate(
  function(lambda) (1 / lambda) * dgamma(lambda, shape = 12, rate = 46),
  lower = 0,
  upper = Inf
)
```

4.181818 with absolute error < 1.4e-05

Parte 4

Graficar la previa y la posterior de λ .

Utilizamos los datos del apartado anterior, sabemos que $\lambda \sim \text{Gamma}(2,1)$ y $\lambda|y \sim \text{Gamma}(12,46)$

Creamos un vector con posibles valores de λ

```
lambda <- seq(0, 6, length.out = 1000)
```

Calculamos las densidades

Para la previa:

```
dens_previa <- dgamma(lambda, shape = 2, rate = 1)
```

Para la posterior:

```
dens_posterior <- dgamma(lambda, shape = 12, rate = 46)
```

Creamos el dataframe con los datos a graficar:


```
datos_grafico <- data.frame(
  lambda = lambda,
  previa = dens_previa,
  posterior = dens_posterior
)
```

```
library(tidyr)
```

```
datos_grafico <- pivot_longer(
  datos_grafico,
  cols = c(previa, posterior),
  names_to = "distribucion",
  values_to = "densidad"
)
```

```
library(ggplot2)

ggplot(datos_grafico,
       aes(x = lambda,
           y = densidad,
           linetype = distribucion,
           color = distribucion)) +
  geom_line()
```



Ejercicio 8 - Previa de Jeffreys

La previa de Jeffreys está dada por $p_J(\theta) \propto \sqrt{I(\theta)}$, donde

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log p(Y|\theta) \right]$$

es la información de Fisher.

Parte a

Sea $Y \sim \text{Binomial}(n, \theta)$ obtener la distribución previa de Jeffreys $p_J(\theta)$ para este modelo

Planteamos la distribución de los datos:

$$p(y|\theta) = \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

Aplicamos logaritmo:

$$\log p(y|\theta) = \log \binom{n}{y} + \log(\theta)y + \log(1-\theta)(n-y)$$

Derivamos respecto a θ :

$$\frac{\partial}{\partial \theta} \log p(y|\theta) = \frac{y}{\theta} - \frac{(n-y)}{1-\theta}$$

Derivada segunda respecto a θ :

$$\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) = -\frac{y}{\theta^2} - \frac{(n-y)}{(1-\theta)^2}$$

Calculamos la esperanza de la densidad de los datos con las transformaciones realizadas, nada depende de y :

$$-E \left[\frac{\partial^2}{\partial \theta^2} \log p(y|\theta) \right] = \frac{n\theta}{\theta^2} + \frac{n-n\theta}{(1-\theta)^2} = \frac{n}{\theta} + \frac{n}{1-\theta}$$

Finalmente la información de Fisher es:

$$I(\theta) = \frac{n}{\theta(1-\theta)}$$

Concluimos con la distribución previa:

$$p(\theta) = n^{1/2} \theta^{-1/2} (1-\theta)^{-1/2} \propto \theta^{-1/2} (1-\theta)^{-1/2}$$

$$\theta \sim \text{Beta}(1/2, 1/2)$$

Parte b

Reparametrizar el modelo binomial usando $\psi = \log(\frac{\theta}{1-\theta})$, de modo que

$$p(y|\psi) = \binom{n}{y} e^{\psi y} (1 + e^\psi)^{-n}$$

Y obtener la distribución *previa* de Jeffreys $p_J(\psi)$ para este modelo.

Para esto seguimos el mismo procedimiento que antes:

Aplicamos logaritmo a la distribución de los datos:

$$\log p(y|\psi) = \log \binom{n}{y} + \psi y - n \log(1 + e^\psi)$$

Derivamos respecto a ψ 2 veces:

$$\frac{\partial}{\partial \psi} \log p(y|\psi) = y - n \left(\frac{e^\psi}{1 + e^\psi} \right)$$

$$\frac{\partial^2}{\partial^2 \psi} \log p(y|\psi) = -n \left(\frac{e^\psi(1 + e^\psi) - e^{2\psi}}{(1 + e^\psi)^2} \right) = -n \left(\frac{e^\psi + e^{2\psi} - e^{2\psi}}{(1 + e^\psi)^2} \right) = -n \frac{e^\psi}{(1 + e^\psi)^2}$$

Por último la esperanza queda igual a lo que ya obtuvimos, ya que no depende de y :

$$I(\psi) = -E \left[\frac{\partial^2}{\partial \psi^2} \log p(y|\psi) \right] = n \frac{e^\psi}{(1 + e^\psi)^2}$$

Terminamos planteando la previa de Jeffreys:

$$\sqrt{I(\psi)} = \sqrt{n \frac{e^\psi}{(1 + e^\psi)^2}} = n^{\frac{1}{2}} \frac{e^{\frac{\psi}{2}}}{1 + e^\psi}$$

$$p_j(\psi) \propto \frac{e^{\frac{\psi}{2}}}{1 + e^\psi}$$

Parte c

Tomar la distribución previa obtenida en el inciso a) y aplicar la fórmula de cambio de variable $\psi = \log\left(\frac{\theta}{1-\theta}\right)$ para obtener la densidad previa de ψ , y comparar si es la misma que la obtenida en el inciso b).

Ahora, Hoff, el ejercicio 3.10 establece que para casos de cambios de variables, si tenemos que $\psi = g(\theta)$ donde g es una función monótona de θ , y tenemos también h siendo la inversa de g de tal forma que $\theta = h(\psi)$. Si $p_\theta(\theta)$ es la distribución de densidad de θ , la distribución de ψ inducida por p_θ está dado por:

$$p_\psi(\psi) = p_\theta(h(\psi)) \times \left| \frac{dh}{d\psi} \right|$$

Primero vamos a definir $p_\theta(h(\psi))$:

En el inciso a) concluimos que la distribución previa es $p_\theta(\theta) = n^{1/2} \theta^{-1/2} (1 - \theta)^{-1/2}$, es decir una $Beta\left(\frac{1}{2}, \frac{1}{2}\right)$

Tomamos $\psi = \log\left(\frac{\theta}{1-\theta}\right)$ que es la función g y despejamos θ

$e^\psi = \frac{\theta}{1-\theta}$ $\theta = \frac{e^\psi}{e^\psi + 1}$ Esta es la función h

Y ahora reemplazamos en $p_\theta(\theta)$

$$p_\theta\left(\frac{e^\psi}{e^\psi + 1}\right) = n^{1/2} \left(\frac{e^\psi}{e^\psi + 1}\right)^{-1/2} \left(1 - \left(\frac{e^\psi}{e^\psi + 1}\right)\right)^{-1/2} \propto \left(\frac{e^\psi}{e^\psi + 1}\right)^{-1/2} \left(\frac{1}{e^\psi + 1}\right)^{-1/2}$$

Simplificamos:

$$p_\theta\left(\frac{e^\psi}{e^\psi + 1}\right) \propto \left(\frac{e^\psi + 1}{e^\psi}\right)^{1/2} (e^\psi + 1)^{1/2} \propto \frac{(e^\psi + 1)^{1/2}}{e^{\psi/2}} (e^\psi + 1)^{1/2} \propto \frac{e^\psi + 1}{e^{\psi/2}}$$

Ahora calculamos $\left|\frac{dh}{d\psi}\right|$:

$$\frac{dh}{d\psi} = \frac{d}{d\psi} \left(\frac{e^\psi}{e^\psi + 1}\right) = \frac{e^\psi(e^\psi + 1) - e^\psi e^\psi}{(e^\psi + 1)^2} = \frac{e^\psi}{(e^\psi + 1)^2}$$

Como $e^\psi > 0$ para todo $\psi \in R$ el valor absoluto se obvia.

$$p_\psi(\psi) \propto \frac{e^\psi + 1}{e^{\psi/2}} \times \frac{e^\psi}{(e^\psi + 1)^2} \propto \frac{e^{\psi/2}}{e^\psi + 1}$$

Comparando este resultado con el obtenido en el punto b:

$$p_j(\psi) \propto \frac{e^{\frac{\psi}{2}}}{1 + e^\psi}$$

Comprobamos que se llega a la misma distribución previa.

Ejercicio 10 - Modelo normal, inferencia para ²

Sea $Y_i \stackrel{\text{i.i.d.}}{\sim} N(m, \sigma^2)$, con m un valor conocido. Observamos $y = (y_1, \dots, y_n)$.

Parte 1

Mostrar que $\sigma^2 \sim \text{Inversa} - \text{Gamma}(a, b)$ es conjugada en este modelo, donde

$$p(\sigma^2) = \frac{b^a}{\Gamma(a)} (\sigma^2)^{-a-1} e^{-b/\sigma^2}$$

Y encontrar los parametros de la distribución posterior.

Para esto primero encontremos la distribución de los datos:

$$p(y_i | \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2} \left(\frac{y_i - m}{\sigma}\right)^2}$$

$$p(y|\sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{1}{2}(\frac{y_i-m}{\sigma})^2} = (\frac{1}{\sqrt{2\pi}})^n \sigma^{-n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i-m)^2}$$

Ahora usando Bayes encontramos la posterior:

$$p(\sigma^2|y) \propto p(y|\sigma^2)p(\sigma^2)$$

$$p(y|\sigma^2)p(\sigma^2) \propto (\sigma^{-n})e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i-m)^2} (\sigma^{-2a-2})e^{-b/\sigma^2} \propto (\frac{1}{\sigma^{2a+2+n}})e^{-\frac{1}{\sigma^2}(b+\frac{1}{2} \sum_{i=1}^n (y_i-m)^2)}$$

$$p(\sigma^2|y) \propto (\frac{1}{\sigma^{2a+2+n}})e^{-\frac{1}{\sigma^2}(b+\frac{1}{2} \sum_{i=1}^n (y_i-m)^2)} \propto (\frac{1}{(\sigma^2)^{a+1+n/2}})e^{-\frac{1}{\sigma^2}(b+\frac{1}{2} \sum_{i=1}^n (y_i-m)^2)}$$

Por último identificamos los parametros de la distribución posterior de la siguiente forma:

$$\sigma^2|y \sim Inv - Gamma \left(a + \frac{n}{2}, b + \frac{1}{2} \sum_{i=1}^n (y_i - m)^2 \right)$$

Como la distribución posterior pertenece a la misma familia Inversa-Gamma que la previa, concluimos que la Inversa-Gamma es conjugada para este modelo.

Parte 2

Calcular la media, la moda y la varuabza de una IG(a,b) en funcion de a y b. Luego utilizar los resultados obtenidos para describir cómo la media y la moda de la psoterior de σ^2 se actualizan respecto de la previa a medida que n crece.

Para la moda debemos maximizar la densidad,

$$p_X(x) = \frac{b^a}{\Gamma(a)} x^{-a-1} e^{-b/x}$$

Aplicamos logaritmo para facilitarnos las cuentas

$$\log p_X(x) = \log \left(\frac{b^a}{\Gamma(a)} \right) - \log(x)(a+1) - \frac{b}{x}$$

Derivamos respecto a x

$$\frac{d}{dx} \log p_X(x) = -(a+1)\frac{1}{x} + \frac{b}{x^2}$$

Igualamos la derivada a 0

$$-\frac{(a+1)}{x} + \frac{b}{x^2} = 0 \Leftrightarrow -(a+1) + \frac{b}{x} = 0 \Leftrightarrow \frac{x}{b} = \frac{1}{a+1} \Leftrightarrow x = \frac{b}{a+1}$$

Entonces

$$\text{moda}(X) = \frac{b}{a+1}$$

Para la media y varianza tenemos expresiones ya conocidas y son:

$$E(X) = \frac{b}{a-1}, \quad a > 1$$

$$V(X) = \frac{b^2}{(a-1)^2(a-2)}, \quad a > 2$$

Ahora veamos la moda y la media de la posterior según los parámetros encontrados, Como $\sigma^2|y \sim \text{Inv-Gamma}\left(a + \frac{n}{2}, b + \frac{1}{2} \sum_{i=1}^n (y_i - m)^2\right)$, entonces $a_n = a + \frac{n}{2}$ y $b_n = b + \frac{1}{2} \sum_{i=1}^n (y_i - m)^2$

Si reemplazamos estos parametros en las formulas definidas antes:

$$\text{moda}(\sigma^2|y) = \frac{b_n}{a_n + 1} = \frac{b + \frac{1}{2} \sum_{i=1}^n (y_i - m)^2}{a + \frac{n}{2} + 1}$$

$$E(\sigma^2|y) = \frac{b_n}{a_n - 1} = \frac{b + \frac{1}{2} \sum_{i=1}^n (y_i - m)^2}{a + \frac{n}{2} - 1}$$

A medida que aumenta n , tenemos más datos disponibles, por lo que la distribución posterior toma cada vez más en cuenta la información aportada por estos datos. Por lo tanto, la media y la moda posteriores dependen cada vez más de las observaciones y menos de los valores a y b de la previa.

Parte 3

Encontrar la previa de Jeffreys para σ^2 .

Recordamos que queremos $p_J(\sigma^2) \propto \sqrt{I(\sigma^2)}$, donde

$$I(\sigma^2) = -E \left[\frac{\partial^2}{\partial \sigma^2} \log p(Y|\sigma^2) \right]$$

En la parte 1 vimos

$$p(Y|\sigma^2) = \left(\frac{1}{\sqrt{2\pi}}\right)^n (\sigma^2)^{-n/2} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - m)^2}$$

Aplicamos logaritmo

$$\log p(Y|\sigma^2) = n \log\left(\frac{1}{\sqrt{2\pi}}\right) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - m)^2$$

Derivamos respecto a σ^2

$$\frac{\partial}{\partial \sigma^2} \log p(Y|\sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (y_i - m)^2$$

Segunda derivada respecto a σ^2

$$\frac{\partial^2}{\partial (\sigma^2)^2} \log p(Y|\sigma^2) = \frac{n}{2(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} \sum_{i=1}^n (y_i - m)^2$$

$$I(\sigma^2) = -E \left[\frac{n}{2(\sigma^2)^2} - \frac{1}{(\sigma^2)^3} \sum_{i=1}^n (y_i - m)^2 \right] = -\frac{n}{2(\sigma^2)^2} + \frac{1}{(\sigma^2)^3} E \left[\sum_{i=1}^n (y_i - m)^2 \right]$$

Ahora nos queda definir $E \left[\sum_{i=1}^n (y_i - m)^2 \right]$

Como $Y_i \sim N(m, \sigma^2)$, entonces:

$$Y_i - m \sim N(0, \sigma^2)$$

Por lo tanto, utilizando la relación entre la esperanza del cuadrado y la varianza:

$$E[(Y_i - m)^2] = \text{Var}(Y_i - m) + [E(Y_i - m)]^2 = \sigma^2$$

Por linealidad de la esperanza:

$$E \left[\sum_{i=1}^n (Y_i - m)^2 \right] = \sum_{i=1}^n E[(Y_i - m)^2] = n\sigma^2$$

Entonces:

$$I(\sigma^2) = -\frac{n}{2(\sigma^2)^2} + \frac{1}{(\sigma^2)^3} n\sigma^2 = -\frac{n}{2(\sigma^2)^2} + \frac{n}{(\sigma^2)^2} = \frac{n}{2(\sigma^2)^2}$$

Concluimos que la previa de Jeffreys es:

$$p_J(\sigma^2) \propto \sqrt{\frac{n}{2(\sigma^2)^2}} \propto \sqrt{\frac{n}{2}} \sqrt{\frac{1}{\sigma^2}} \propto \frac{1}{\sigma^2}$$

Parte 4

¿Es la previa de Jeffreys encontrada el caso límite de la previa conjugada? ¿Para qué valores de a y b?

Para estas preguntas vamos a usar la previa de Jeffreys y la previa dada en la parte 1, la cual ya comprobamos que es conjugada:

$$p(\sigma^2) = \frac{b^a}{\Gamma(a)} (\sigma^2)^{-a-1} e^{-b/\sigma^2} \propto (\sigma^2)^{-a-1} e^{-b/\sigma^2}$$

La previa de Jeffreys obtenida en la parte anterior es:

$$p_J(\sigma^2) \propto (\sigma^2)^{-1}$$

Para determinar si la previa de Jeffreys es el caso límite de la previa conjugada, busquemos los valores de a y b que hagan que la forma de la Inversa-Gamma coincida con la previa de Jeffreys.

$$(\sigma^2)^{-a-1} e^{-b/\sigma^2} \propto \sigma^{-2}$$

Para que la igualdad se cumpla se deben comprobar las siguientes igualdades $-a - 1 = -1$ y $-\frac{b}{\sigma^2} = 0$, entonces tomando $a \rightarrow 0$ y $b \rightarrow 0$ en la previa conjugada:

$$\lim_{a \rightarrow 0, b \rightarrow 0} (\sigma^2)^{-a-1} e^{-b/\sigma^2} = (\sigma^2)^{-1} e^0 = (\sigma^2)^{-1}$$

Parte 5

Definir una opción débilmente informativa para σ^2 . Justificar la elección comparando la dispersión que la previa le asigna a σ^2 con la escala de variabilidad que uno esperaría razonablemente en los datos del problema.

Primero definimos a una *previa débilmente informativa*, como una que:

- descarte valores de σ^2 que no tienen sentido;
- pero sea suficientemente flexible como para tener poco efecto sobre la posterior.

Entonces para una propuesta de una previa débilmente informativa, vamos a trabajar con una reparametrización de σ^2 :

$$\eta = \log(\sigma^2)$$

Elegimos esta reparametrización ya que σ^2 solo puede tomar valores positivos, mientras que η puede tomar cualquier valor real, de esta forma podemos trabajar con una distribución normal, osea podemos plantear una distribución previa directamente sobre η .

Proponemos entonces:

$$\eta \sim N(\mu, \tau^2)$$

De esta forma, los valores posibles de σ^2 quedan determinados por

$$\sigma^2 = e^\eta$$

Los parámetros μ y τ^2 se elegirán de forma que la previa sea suficientemente dispersa para permitir valores razonables de σ^2 .

Dado que el enunciado no proporciona datos observados ni una escala de variabilidad esperada para y_i , no tenemos información suficiente para elegir los parámetros de la previa en función del problema concreto. Por lo tanto, se propone, a modo ilustrativo, tomar $\sigma^2 = 1$, ya que no contamos con observaciones que permitan determinar una escala a partir de los datos.

Como estamos trabajando con $\eta = \log(\sigma^2)$, esto implica:

$$\mu = \log(1) = 0$$

Entonces:

$$\eta \sim N(0, \tau^2)$$

Ahora elegimos τ^2 de manera que la previa sea suficientemente amplia.

Por ejemplo, podemos tomar $\tau^2 = 4$ de modo que $\eta \sim N(0, 4)$, de esta forma logramos que la previa permita valores de σ^2 bastante alejados de 1.

Podemos comprobar qué valores de σ^2 permite de la siguiente forma:

Tomamos aproximadamente dos desviaciones estándar de η :

$$-4 \leq \eta \leq 4$$

Como $\sigma^2 = e^\eta$,

$$e^{-4} \leq \sigma^2 \leq e^4$$

es decir,

$$0,018 \lesssim \sigma^2 \lesssim 54,6$$

Eso muestra que la previa permite un intervalo amplio de valores positivos para σ^2 .